

## Sistemas Avanzados de Producción

### Taller #1

Presentado por:

- Julián David Sánchez Gómez (123758)
- Nicolas Andrés Chacón Suesca (123692)
- Mónica Andrea Gallego Ramos (120689)
- Fabian Moisés Callender Diaz (124597)

### Fase 1: Estadística Descriptiva y Análisis Exploratorio

#### Medidas de Tendencia Central y Dispersión

| Variable  | Mean     | Median | Std       | Min | Max   | Skewness  | Kurtosis  |
|-----------|----------|--------|-----------|-----|-------|-----------|-----------|
| TV        | 147.0425 | 149.75 | 85.854236 | 0.7 | 296.4 | -0.069853 | -1.226495 |
| radio     | 23.2640  | 22.90  | 14.846809 | 0.0 | 49.6  | 0.094175  | -1.260401 |
| newspaper | 30.5540  | 25.75  | 21.778621 | 0.3 | 114.0 | 0.894720  | 0.649502  |
| sales     | 14.0225  | 12.90  | 5.217457  | 1.6 | 27.0  | 0.407571  | -0.408869 |

Tabla [1]: Esta tabla muestra las medidas de tendencia central y dispersión por variables independientes y la variable Sales dependiente.

#### Análisis de Distribución y Atípicos:




Figura [1]: En la parte superior encontramos los histogramas de las variables de TV, Radio, Newspaper y Ventas y sus respectivos Boxplot.

#### Simetría de las distribuciones

- **TV:** La distribución muestra una simetría aproximada, con ligeros cambios en los extremos, pero no tiene un sesgo significativo. La mediana está más o menos centrada en el boxplot, lo cual indica un comportamiento cercano a la normalidad.

- **Radio:** Se aprecia una distribución muy equilibrada, con dispersión uniforme y sin colas acentuadas. No se observa una asimetría significativa.
- **Newspaper:** Tiene una asimetría positiva (con la cola hacia la derecha), mostrando una mayor concentración de valores bajos y algunos altos que se sitúan lejos de la masa central.
- **Sales:** Muestra una distribución casi simétrica con ligera asimetría positiva, con la mayor parte de las observaciones concentradas en valores medios.

### Datos atípicos

- En Newspaper, se detectan valores atípicos superiores. Se pueden observar en el boxplot como puntos que están fuera de los bigotes.
- No se observan outliers extremos importantes en TV, Radio y Sales.

### ¿Cómo podrían influir estas observaciones en la trayectoria de una línea de regresión?

- Dado que el método de mínimos cuadrados minimiza los errores cuadráticos, los valores atípicos pueden tener un impacto desproporcionado en la estimación de los coeficientes de la regresión lineal.
- Un valor extremo tiene el potencial de alterar la pendiente, inclinando la línea recta hacia su dirección.
- Además, tiene la capacidad de modificar el intercepto y incrementar la varianza residual.

En esta situación, los valores atípicos en Newspaper podrían modificar un poco su coeficiente estimado. Sin embargo, es posible que su efecto total sobre el modelo no sea significativo debido a que la relación con Sales es débil.

### Exploración de la Nube de Puntos




Figura [2]: En la parte superior encontramos los dispersogramas de las variables de TV, Radio, Newspaper en comparación con la variable Sales.

- **TV vs Sales:** La nube de puntos muestra una tendencia lineal positiva clara, con un aumento constante en las ventas cuando el presupuesto de televisión se incrementa. No hay patrones que sigan una curva (parabólicos) ni divisiones perceptibles. La dispersión en torno a la tendencia es relativamente uniforme, lo que indica que un modelo de regresión lineal simple es apropiado para caracterizar la relación.
- **Radio vs Sales:** Se observa una correlación positiva que es casi lineal, aunque más dispersa que en televisión. No se observan patrones no lineales significativos; no obstante, la variabilidad es más alta en niveles de inversión elevados, lo que puede sugerir una ligera heterocedasticidad. Sin embargo, la estructura general es compatible con un modelo lineal.
- **Newspaper vs Sales:** La nube de puntos indica que no existe una tendencia lineal clara. La dispersión es extensa y no se nota una dirección definida en la relación. Hay ciertas observaciones influyentes que se encuentran a una distancia de la masa principal. No se observan visualmente patrones segmentados o en forma de parábola, pero la correlación lineal es débil.

### Evaluación de Asociación




Figura [3]: En la parte superior encontramos la matriz de correlación de Pearson.




Figura [4]: En la parte superior encontramos la matriz de correlación de Spearman.

### ¿Qué significa un coeficiente cercano a 1 o -1 en el contexto de la inversión publicitaria y el retorno en ventas?

- Un coeficiente que se aproxima a 1 señala una relación positiva muy intensa, lo que significa que, si la inversión en publicidad aumenta, el retorno de las ventas también lo hace de manera constante y previsible.
- En esta situación, valores como 0.78 - 0.80 (TV vs Ventas) significan que la inversión en televisión está estrechamente relacionada con el incremento de las ventas.
- Un coeficiente próximo a -1 señalaría una relación negativa fuerte, lo que indicaría que las ventas se reducirían de manera sistemática si la inversión creciera (una situación que no se presenta en este análisis).

### ¿Cómo se interpreta un valor de correlación cercano a 0?

Cuando el coeficiente está cerca de cero, esto señala que no existe una relación lineal significativa entre las variables.

Esto implicaría, en términos de publicidad, que la inversión en ese medio no está claramente relacionada con el comportamiento de las ventas.

**Compare ambos coeficientes (Pearson y Spearman).**

**¿Sugieren estos resultados que las relaciones son estrictamente lineales?  
Justifique su respuesta basándose en la forma de la nube de puntos observada.**

Primero debemos tener en cuenta que Spearman mide la relación monótona (por rangos), mientras que Pearson mide la relación lineal.

Por lo cual frente a los resultados:

- **TV vs ventas:** Spearman = 0.80 y Pearson = 0.78
- **Radio vs. Ventas:** Spearman = 0.55 y Pearson = 0.58
- **Newspaper vs ventas:** Spearman = 0.19 y Pearson = 0.23

Los coeficientes son muy parecidos en todos los casos, lo que señala que:

- Las relaciones son principalmente lineales.
- No hay patrones no lineales sólidos (como segmentos o parábolas).
- Esta interpretación es confirmada por la forma de la nube de puntos:
  - Se puede notar una tendencia creciente casi lineal en la televisión y la radio.
  - En Newspaper, la dispersión es elevada y no se distingue una tendencia definida.

Si Spearman hubiera sido significativamente mayor a Pearson, podría haber propuesto una relación monótona que no fuera estrictamente lineal. No obstante, como los dos coeficientes son semejantes, se concluye que las relaciones observadas son en su mayoría lineales y apropiadas para un modelo de regresión lineal, particularmente en el caso de TV.

## **Fase 2: Regresión Lineal y Diagnóstico**

### **1. Modelamiento múltiple**

```
✓ ... Intercepto (beta_0): 2.9389  
    Pendiente (beta_1): 0.0458  
    Pendiente (beta_2): 0.1885  
    Pendiente (beta_3): -0.0010
```

### **2. Interpretación de parámetros**

- Interprete el intercepto  $\beta_0$  indicando si tiene sentido conceptual que sea diferente de cero.
- **Intercepto ( $\hat{\beta}_0 = 2.9389$ )**

Representa el valor esperado de las ventas cuando la inversión en TV, Radio y Newspaper es igual a 0.

Si no se invierte en publicidad, las ventas esperadas serían aproximadamente 2.94 unidades.

- Interprete los coeficientes  $\hat{\beta}_1$ ,  $\hat{\beta}_2$  y  $\hat{\beta}_3$  bajo el concepto de variación de la media de Y cuando hay un incremento unitario de la covariable, manteniendo la otra constante (ceteris paribus).

- **Pendiente ( $\hat{\beta}_1 = 0.0458$ )**

Representa el cambio esperado en las ventas por cada unidad adicional invertida en TV, manteniendo constantes las demás variables.

Por cada unidad adicional invertida en TV, las ventas aumentan aproximadamente 0.0458 unidades, si Radio y Newspaper permanecen constantes.

- **Pendiente ( $\hat{\beta}_2 = 0.1885$ )**

Representa el cambio esperado en las ventas por cada unidad adicional invertida en Radio, manteniendo constantes las demás variables.

Por cada unidad adicional invertida en Radio, las ventas aumentan aproximadamente **0.1885 unidades**, si TV y Newspaper permanecen constantes.


- **Pendiente ( $\hat{\beta}_3 = 0.1885$ )**

Representa el cambio esperado en las ventas por cada unidad adicional invertida en Newspaper, manteniendo constantes las demás variables.


Por cada unidad adicional invertida en Newspaper, las ventas disminuyen aproximadamente 0.0010 unidades, manteniendo constantes las demás inversiones.

### 3. Análisis de Bondad de ajuste


#### Regresión lineal simple $R^2$ TV



### Regresión lineal simple $R^2$ radio



### Regresión lineal simple $R^2$ newspaper



```
import numpy as np
from sklearn.metrics import mean_squared_error
mse = mean_squared_error(y, y_pred)
rmse = np.sqrt(mse)
print(f"Error Cuadrático Medio (MSE): {mse:.4f}")
print(f"Raíz del Error Cuadrático Medio (RMSE): {rmse:.4f}")
```

---

```
Error Cuadrático Medio (MSE): 2.7841
Raíz del Error Cuadrático Medio (RMSE): 1.6686
```

### Interpretación R<sup>2</sup>

```
*** --- Coeficientes del Modelo ---
Intercepto (beta_0): 2.9389
Coeficiente TV (beta_1): 0.0458
Coeficiente Radio (beta_2): 0.1885
Coeficiente newspaper (beta_3): -0.0010

--- Bondad de Ajuste ---
R-cuadrado (R2): 0.8972
```

El modelo de regresión lineal explica el 89,72% de la variabilidad observada en las ventas a partir de las variables TV, radio y newspaper.

### 4. Estimación Matricial

Dadas las matrices de diseño X y el vector de respuesta Y :

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad Y = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$



**Tarea:**

- Calcule la matriz transpuesta  $X'$

Matrx transpuesta de  $X$ .

$$X^T = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix}$$

- Calcule el producto  $X'X$  y su respectiva matriz inversa  $(X'X)^{-1}$ .

②  $X'X$

$$X^T \cdot X = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \cdot \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix} = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix} A$$

Inversa  $(X'X)^{-1}$

•  $\frac{(Adj A)^T}{\det A}$        $\det A = 5 \times 55 - 15 \times 15$   
 $\det A = 50$

$$\left[ \frac{Adj A = \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix}}{50} \right]^T A^{-1}$$

- Calcule el producto  $X'Y$ .

③  $X'Y$

$$X^T Y = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \cdot \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

Primer elemento:  
 $2 + 4 + 6 + 7 + 9 = 28$

Segundo elemento:  
 $2 + 8 + 18 + 28 + 45 = 101$

$$X'Y = \begin{pmatrix} 28 \\ 101 \end{pmatrix}$$

- Obtenga el vector de parámetros  $\hat{\beta}$  y escriba la ecuación de la recta estimada  $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ .

- Obtener el vector de parámetros  $\hat{\beta}$

$$\hat{\beta} = (X'X)^{-1} X'Y$$

$$\hat{\beta} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} \begin{pmatrix} 28 \\ 101 \end{pmatrix}$$

Multiplicación de matrices.

①  $55 \cdot 28 + (-15) \cdot 101 = 25$

②  $-15(28) + 5(101) = 85$

$$\hat{\beta} = \frac{1}{50} \begin{pmatrix} 25 \\ 85 \end{pmatrix} = \begin{pmatrix} 0.5 \\ 1.7 \end{pmatrix}$$

### Fase 3: Árboles de Decisión y Comparación de Modelos

#### Entrenamiento del modelo

Estructura del Árbol de Regresión: Ventas vs (TV y Radio)





Figura [5]: En la parte superior encontramos la estructura del árbol de regresión entre Ventas vs TV y Radio.

El algoritmo busca, en cada etapa, el punto de corte de las variables predictoras (como la radio o la televisión) que produzca la reducción más grande posible en la varianza de la variable objetivo (ventas). Las divisiones se llevan a cabo en los nodos del árbol de regresión siguiendo el criterio de minimizar el error cuadrático. Para lograrlo, examina diferentes valores de división y escoge aquel que cree grupos con mayor homogeneidad, o sea, en los que los valores de ventas en cada nodo sean lo más parecidos posible. Este proceso se repite de forma recursiva en cada subnodo hasta que ya no se obtiene un avance significativo o se satisface un criterio de parada, como una cantidad mínima de muestras o una profundidad máxima en el árbol.

### Cálculo Manual de Incertidumbre (Clasificación):



### Importancia de Predictores

La importancia de predictores en un árbol de decisión se determina con base en la reducción de la varianza (en regresión) que produce cada variable al realizar una partición. Es decir, la variable que más reduce el error cuadrático en los nodos superiores del árbol tendrá mayor peso dentro del modelo.

En el árbol de regresión entrenado con las variables TV y Radio, se observa que:

- TV tiene mayor importancia relativa, ya que generalmente aparece en los primeros niveles del árbol y genera una mayor reducción de la varianza en las ventas.
- Radio también contribuye a la predicción, pero su impacto es menor comparado con TV.

Este resultado es consistente con lo observado en la Fase 2, donde en la regresión múltiple:

- TV mostró una relación fuerte con las ventas.

- Radio tuvo un efecto positivo, pero menor.
- Newspaper presentó una contribución débil.

Por tanto, tanto el árbol de decisión como la regresión múltiple coinciden en que TV es el predictor más influyente en el comportamiento de las ventas.

### **Diagnóstico Comparativo:**

Al comparar la regresión lineal múltiple con el árbol de decisión, se pueden identificar diferencias importantes en términos de interpretabilidad y precisión.

### **Regresión Lineal**

Ventajas:

- Alta interpretabilidad.
- Permite cuantificar exactamente cuánto aumentan las ventas ante un incremento unitario en la inversión.
- Es adecuada cuando la relación entre variables es aproximadamente lineal.

Desventajas:

- Supone linealidad.
- Puede verse afectada por valores atípicos.

En este caso, dado que las relaciones observadas entre TV y ventas son principalmente lineales, la regresión lineal resulta un modelo apropiado.

### **Árbol de Decisión**

Ventajas:

- No requiere asumir linealidad.
- Capta posibles relaciones no lineales o interacciones.
- Es visual e intuitivo.

Desventajas:

- Puede sobre ajustarse si no se poda adecuadamente.
- Puede ser menos estable ante pequeñas variaciones en los datos.

## **Conclusión**

En el presente análisis se compararon dos enfoques de modelamiento predictivo: la regresión lineal múltiple y el árbol de decisión, con el fin de identificar cuál resulta más robusto para explicar el comportamiento de las ventas a partir de la inversión en publicidad.

Los resultados muestran que la regresión lineal múltiple es el modelo más adecuado para este caso particular. Esto se debe a que las relaciones entre las variables predictoras (especialmente TV y Radio) y la variable respuesta (Sales) presentan una tendencia principalmente lineal, como se evidenció en los dispersogramas y en los coeficientes de correlación. Además, el modelo lineal logró un alto nivel de explicación de la variabilidad de las ventas, lo que respalda su capacidad predictiva.

Por otro lado, el árbol de decisión permitió visualizar la segmentación de los datos y entender cómo ciertos niveles de inversión generan diferentes comportamientos en ventas. Sin embargo, al tratarse de relaciones mayormente lineales y sin patrones complejos o interacciones fuertes, el árbol no aporta una mejora sustancial frente al modelo lineal y puede ser más sensible a variaciones en los datos.

En conclusión, para este conjunto de datos y bajo las condiciones analizadas, la regresión lineal múltiple se considera más robusta debido a su mayor estabilidad, interpretabilidad y coherencia con la estructura de los datos. El árbol de decisión sería más conveniente en escenarios donde existan relaciones no lineales marcadas o segmentaciones claras del mercado.